SENATI

Servicio Nacional de Adiestramiento en Trabajo Industrial

TRABAJO FINAL

Fundamentos y Algoritmia para Inteligencia Artificial

Sistema de detección de riesgo de deserción estudiantil

Modelo de Machine Learning y aplicativo web con Python, Flask, HTML y CSS

Integrantes	[Completar con los nombres del equipo]
Instructor	Ing. Gunar Castro Iñigo
Sede	[Completar]
Curso	Fundamentos y Algoritmia para Inteligencia Artificial
Fecha	Octubre de 2026

Contenido

1. Introducción
2. Planteamiento del problema
3. Objetivos
4. Descripción del dataset
5. Exploración de datos
6. Preprocesamiento
7. Fundamento matemático
8. Análisis estadístico
9. Visualización
10. Modelo de Machine Learning
11. Aplicativo web
12. Resultados
13. Limitaciones
14. Conclusiones
15. Recomendaciones
16. Anexos

1. Introducción

La deserción estudiantil es uno de los principales desafíos de las instituciones de formación técnica. Cada estudiante que abandona representa un proyecto de vida interrumpido y un esfuerzo institucional que no llega a su meta. Gran parte de los abandonos no ocurre de forma repentina: antes aparecen señales como la baja asistencia, la acumulación de cursos desaprobados, las dificultades económicas, los problemas de conectividad o el poco uso de la plataforma académica.

Detectar estas señales de forma temprana permite que tutores y responsables académicos intervengan cuando todavía hay margen de acción. Este trabajo desarrolla una solución de Inteligencia Artificial que analiza la información disponible de cada estudiante y estima su riesgo de abandono, y la entrega mediante un aplicativo web usable desde computadora, tablet y celular.

El sistema **no toma decisiones automáticas** sobre el estudiante: es una herramienta de apoyo para priorizar la revisión del tutor.

2. Planteamiento del problema

La institución cuenta con información académica dispersa en diferentes registros que no se utiliza de manera sistemática para identificar riesgo. Cuando las señales se detectan demasiado tarde, las posibilidades de intervención disminuyen. Se requiere una herramienta que integre variables académicas y contextuales y estime la probabilidad de abandono de cada estudiante, de forma comprensible para quienes no son especialistas en datos.

Pregunta que guía el proyecto: ¿es posible estimar, a partir de datos académicos y contextuales, qué estudiantes tienen mayor riesgo de abandonar, con una capacidad de detección suficiente para servir como apoyo a la tutoría?

3. Objetivos

Objetivo general

Desarrollar un modelo de clasificación basado en Machine Learning que estime el riesgo de deserción estudiantil a partir de variables académicas y contextuales, complementado con una aplicación web desarrollada con Python, Flask, HTML y CSS.

Objetivos específicos

- Cargar y explorar el dataset con Pandas, identificando tipos de variables, valores nulos y problemas de calidad.
- Preprocesar variables numéricas y categóricas (imputación, escalado y codificación) evitando fuga de información.
- Aplicar operaciones de álgebra lineal con NumPy y calcular media, mediana, varianza y desviación estándar.
- Identificar valores atípicos y crear visualizaciones interpretables.
- Entrenar y evaluar un modelo de clasificación con métricas apropiadas, priorizando el recall de la clase abandono.
- Guardar el pipeline en un archivo .pkl e integrarlo en una aplicación web con Flask, con diseño responsive.
- Documentar técnica y funcionalmente el proyecto y publicarlo en GitHub y Vercel.

4. Descripción del dataset

El archivo **dataset_riesgo_desercion_estudiantil.csv** fue entregado por el instructor para este trabajo. Contiene **600 registros** y **24 columnas**. **Es un dataset sintético con comportamiento realista**: no contiene información real de estudiantes de SENATI ni de ninguna otra institución.

La variable objetivo es **abandono** (0 = el estudiante continúa, 1 = abandona). La columna **riesgo_referencial** se incluye solo como referencia para análisis y visualización y **no se usa como predictora**, para evitar fuga de información. El identificador **id_estudiante** tampoco se usa.

Diccionario de datos

Elaborado por el equipo a partir de los nombres y valores de cada columna.

Variable	Tipo	Descripción
id_estudiante	Texto	Identificador único (EST-0001 a EST-0600). No se usa en el modelo
sede	Categórica	Sede (6): Arequipa, Huancayo, Independencia, Lima Norte, San Juan de Lurigancho, Trujillo
programa	Categórica	Programa de estudios (5 programas)
turno	Categórica	Mañana, Tarde o Noche
semestre	Numérica	Semestre cursado (1 a 6)
edad	Numérica	Edad en años (17 a 33)
promedio_academico	Numérica	Promedio de notas en escala 0 a 20 (8 nulos)
asistencia_pct	Numérica	Porcentaje de asistencia (7 nulos)
faltas_mes	Numérica	Faltas registradas en el mes
tardanzas_mes	Numérica	Tardanzas registradas en el mes
cursos_desaprobados	Numérica	Cantidad de cursos desaprobados
horas_estudio_semana	Numérica	Horas de estudio por semana (9 nulos)
uso_plataforma_horas	Numérica	Horas de uso de la plataforma académica (8 nulos)
tutorias_mes	Numérica	Tutorías recibidas en el mes
satisfaccion_formacion_1a5	Numérica	Satisfacción con la formación, de 1 a 5 (6 nulos)
trabaja_actualmente	Categórica	Sí / No
horas_trabajo_semana	Numérica	Horas de trabajo por semana
distancia_centro_km	Numérica	Distancia a la sede en km
tiempo_traslado_min	Numérica	Tiempo de traslado en minutos
situacion_pago	Categórica	Al día, 1 cuota pendiente, 2 o más cuotas pendientes
calidad_conectividad	Categórica	Buena, Regular o Limitada (5 nulos)
apoyo_familiar	Categórica	Alto, Medio o Bajo (5 nulos)

Variable	Tipo	Descripción
riesgo_referencial	Categórica	Riesgo Bajo/Medio/Alto de referencia. No se usa como predictora
abandono	Objetivo	0 = continúa, 1 = abandona

5. Exploración de datos

Se realizó con Pandas antes de modificar cualquier dato. Los hallazgos principales son:

- El dataset tiene **600 filas y 24 columnas**: 14 variables numéricas, 7 categóricas, un identificador, la variable de referencia y el objetivo.
- Hay **48 valores nulos** en 7 columnas, ninguna con más de 1,5 % de datos faltantes: promedio académico (8), asistencia (7), horas de estudio (9), uso de plataforma (8), satisfacción (6), conectividad (5) y apoyo familiar (5).
- **El dataset está desbalanceado**: 500 estudiantes continúan (83,3 %) y 100 abandonan (16,7 %), una proporción cercana a 5 a 1.
- Las variables numéricas más asociadas con el abandono son el promedio académico (correlación −0,22), las faltas al mes (+0,20) y la asistencia (−0,17).
- La tasa de abandono casi se duplica con apoyo familiar bajo (26,0 % frente a 12,8 % con apoyo alto), con 2 o más cuotas pendientes (28,0 % frente a 14,5 % al día) y con conectividad limitada (25,9 %). Arequipa (22,9 %) y Lima Norte (21,8 %) superan a las demás sedes (cerca de 12 %).

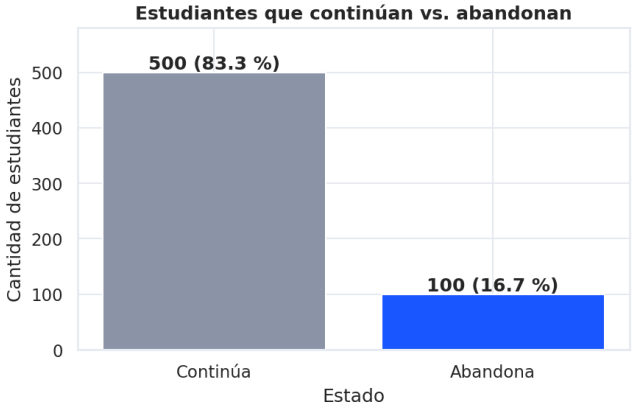


Figura 1. Distribución de la variable objetivo.

Interpretación: el desbalance obliga a no evaluar solo con accuracy: un modelo que siempre responda 'continúa' acertaría el 83 % de las veces y no detectaría a ningún estudiante en riesgo.

6. Preprocesamiento

Decisión	Justificación
Excluir id_estudiante y riesgo_referencial	El identificador no aporta información; la variable de referencia produciría fuga de información
Nulos numéricos: mediana	Es robusta frente a valores extremos
Nulos categóricos: moda	Conserva la categoría más frecuente
Numéricas: StandardScaler	La regresión logística es sensible a la escala de las variables

Decisión	Justificación
Categóricas: OneHotEncoder	Crea columnas 0/1 sin imponer un orden artificial; ignora categorías desconocidas
Separación 80 % / 20 % con stratify=y	Conserva la proporción 83/17 en entrenamiento (480 filas, 80 abandonos) y prueba (120 filas, 20 abandonos)

Todas las transformaciones se encapsulan en un **ColumnTransformer** dentro de un **Pipeline** de Scikit-learn. De esta forma el preprocesamiento se ajusta únicamente con los datos de entrenamiento y se aplica sin cambios a los datos de prueba y a los nuevos estudiantes que ingresen por la aplicación web, evitando la fuga de datos.

7. Fundamento matemático

Se trabajó con NumPy usando datos reales del proyecto. Cada estudiante es un **vector** de indicadores [promedio, asistencia, faltas, cursos desaprobados] y el conjunto de estudiantes es una **matriz** (filas = estudiantes, columnas = variables).

Matriz de 5 estudiantes (5 x 4), el estudiante A es la primera fila y B la segunda: A = [13.4, 97.6, 1.0, 1.0], B = [15.5, 80.0, 4.0, 2.0].

Operación	Resultado	Qué representa
A + B	[28.9, 177.6, 5.0, 3.0]	Acumulado de indicadores de dos estudiantes
A − B	[-2.1, 17.6, -3.0, -1.0]	Diferencia entre dos perfiles, indicador por indicador
Producto punto A · pesos	43.480	Puntaje ponderado; es la operación base de la regresión logística (w · x + b)
Norma de A	98.526	Longitud o magnitud global del vector
Norma de A − B	18.005	Distancia entre dos estudiantes: menor valor, perfiles más parecidos
M @ pesos (5 estudiantes)	[43.48, 36.72, 38.85, 39.79, 45.18]	Puntaje de todos los estudiantes a la vez

Sistema de ecuaciones lineales. Un tutor usa un puntaje de seguimiento = a·promedio + b·(asistencia/10) + c·faltas, y se conoce el puntaje de tres estudiantes. Con **np.linalg.solve()** se recuperan los pesos: el determinante de la matriz de coeficientes es -34.57 (distinto de cero, por lo que la solución es única) y la solución es (a, b, c) = (0.50, 0.30, -0.40), que coincide con los pesos originales (0,50; 0,30; −0,40).

En Machine Learning el mismo principio aparece al ajustar los pesos de un modelo, aunque allí hay más observaciones que incógnitas y se resuelve por optimización.

8. Análisis estadístico

La varianza y la desviación estándar se calcularon manualmente con una función propia (varianza muestral, ddof = 1) y con NumPy. **Ambos resultados coinciden exactamente**.

Variable	Media	Mediana	Varianza	Desv. estándar
promedio_academico	13,736	13,70	5,907	2,431

Variable	Media	Mediana	Varianza	Desv. estándar
asistencia_pct	83,576	84,30	112,383	10,601
horas_estudio_semana	10,388	10,50	15,989	3,999
tiempo_traslado_min	40,452	38,00	388,001	19,698

- **Promedio académico:** media y mediana casi iguales, distribución simétrica; desviación de 2,4 puntos.
- **Asistencia:** media de 83,6 %; 10 estudiantes están por debajo del 60 %.
- **Horas de estudio:** alta variabilidad entre estudiantes (de 1 a 22,6 horas por semana).
- **Traslado:** la media supera a la mediana, señal de cola a la derecha por trayectos largos.

Valores atípicos

Variable	Atípicos (IQR)	Atípicos (z > 3)	Observación
promedio_academico	3	1	Promedios muy bajos (6,3 a 7,1)
asistencia_pct	0	0	Sin atípicos
horas_estudio_semana	2	1	Más de 21 horas semanales
tiempo_traslado_min	11	6	Trayectos de 94 a 114 minutos

Decisión: no se eliminaron. Son valores posibles en la realidad y corresponden justamente al perfil que interesa detectar (por ejemplo, un estudiante con promedio muy bajo o que vive lejos). El escalado y la regularización de la regresión logística limitan su influencia.

9. Visualización

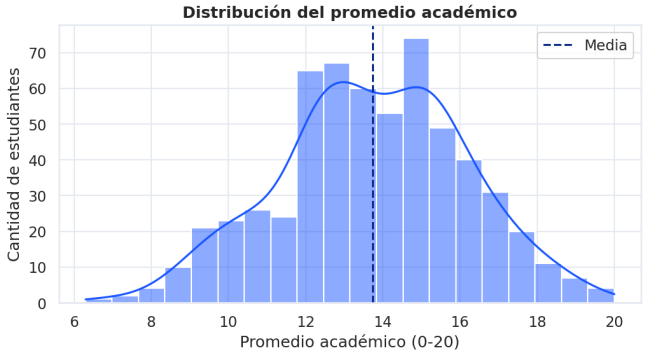


Figura 2. Histograma del promedio académico.

Interpretación: Distribución aproximadamente normal centrada cerca de 13,7; pocos estudiantes con promedios menores a 9.

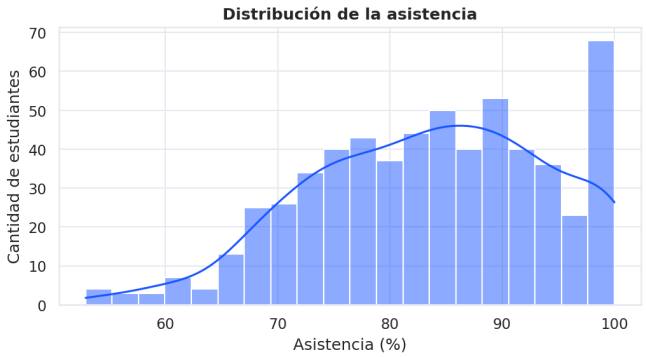


Figura 3. Distribución de la asistencia.

Interpretación: Se concentra entre 75 % y 95 %, con una cola hacia valores bajos que identifica a quienes asisten poco.

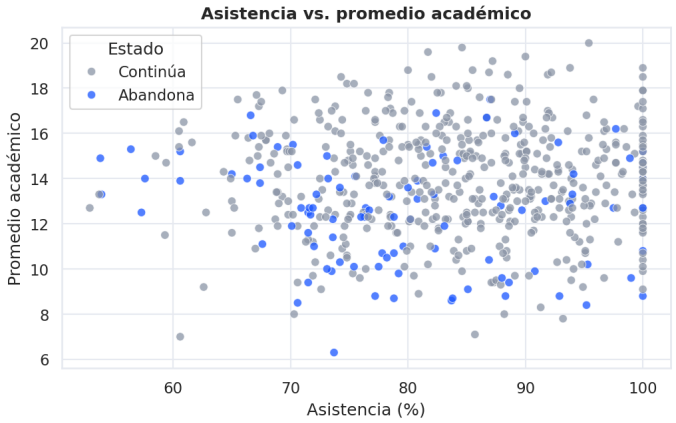


Figura 4. Dispersión de asistencia y promedio.

Interpretación: Casi no hay relación entre ambas (correlación 0,02), por lo que aportan información distinta al modelo.

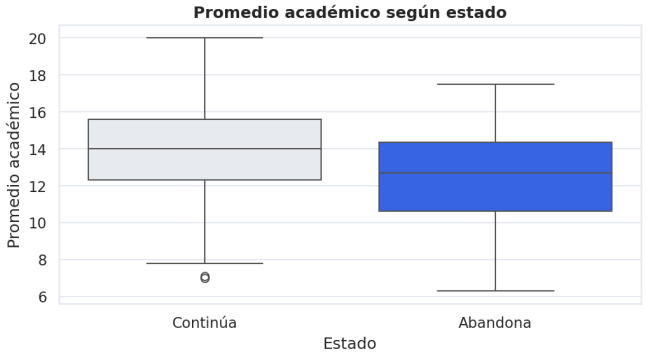


Figura 5. Boxplot del promedio según estado.

Interpretación: La mediana del promedio es menor en quienes abandonan; los puntos fuera de los bigotes son los atípicos conservados.

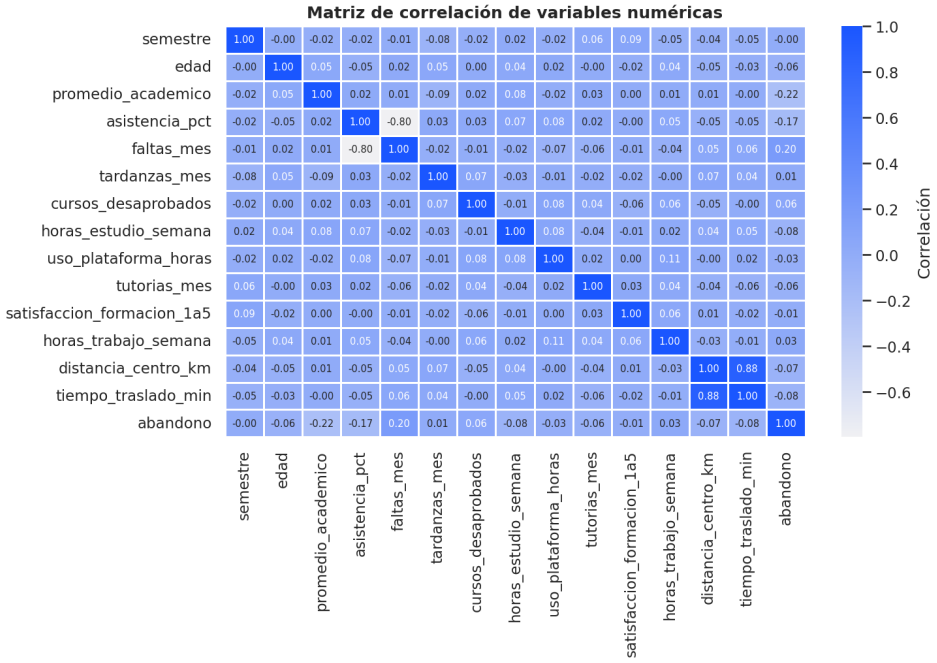


Figura 6. Matriz de correlación de variables numéricas.

Interpretación: Distancia y tiempo de traslado están muy correlacionadas (0,88), igual que faltas y asistencia (−0,80). Esta redundancia justifica la regularización.

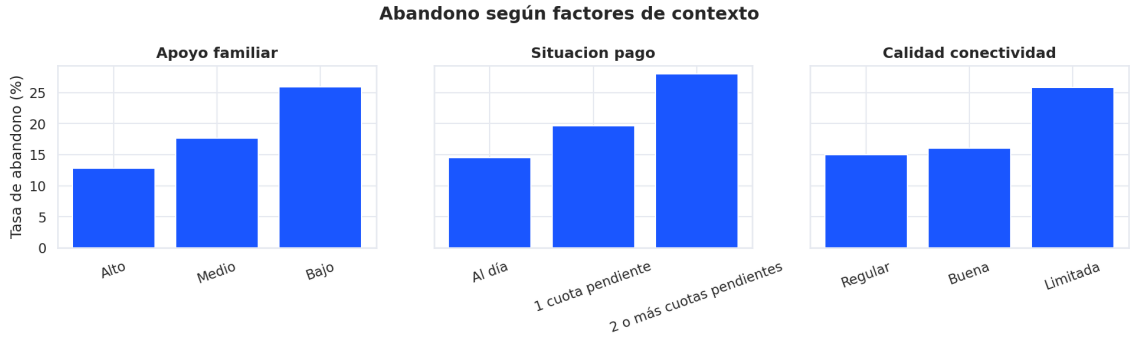


Figura 7. Abandono según factores de contexto.

Interpretación: El abandono casi se duplica con apoyo familiar bajo, 2 o más cuotas pendientes y conectividad limitada: factores que un tutor puede atender.

10. Modelo de Machine Learning

El modelo final es una **Regresión Logística** con **class_weight='balanced'** (para compensar el desbalance 5 a 1) y regularización **C = 0,1**. Se eligió frente a Random Forest por tener mucho mayor recall y ser interpretable.

Proceso de entrenamiento

- División estratificada 80 % / 20 % y pipeline de preprocesamiento (sección 6).
- Comparación de Regresión Logística y Random Forest con validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento.
- Búsqueda del hiperparámetro C maximizando el recall. C = 0,01 y C = 0,1 dieron recall similar (0,61 y 0,60); se eligió 0,1 porque con 0,01 las probabilidades quedan comprimidas cerca de 0,5 y los niveles de riesgo pierden utilidad.

- Evaluación final sobre el conjunto de prueba, análisis de errores y guardado del pipeline completo en modelo_desercion.pkl.

Comparación de modelos (validación cruzada)

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión Logística	0.696	0.283	0.538	0.368	0.672
Random Forest	0.825	0.400	0.075	0.123	0.681

Con el umbral estándar de 0,5, el Random Forest casi no detecta casos de abandono (recall de 0,08): con solo 80 casos positivos tiende a memorizar. La regresión logística generaliza mejor.

Métricas en el conjunto de prueba (120 estudiantes, 20 abandonan)

Accuracy	Precision	Recall	F1-score	ROC-AUC
0.758	0.371	0.650	0.473	0.742

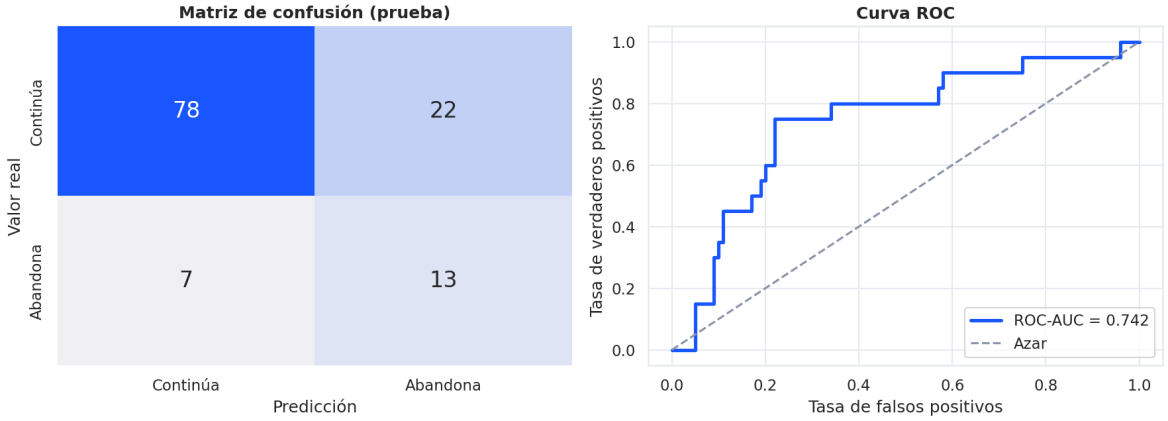


Figura 8. Matriz de confusión y curva ROC en el conjunto de prueba.

Matriz de confusión: 78 verdaderos negativos, 22 falsos positivos, 7 falsos negativos y 13 verdaderos positivos. El modelo detecta **13 de los 20** estudiantes que abandonan (recall 0,65). La precision de 0,37 implica falsas alertas, un costo aceptable: revisar a un estudiante cuesta poco; no detectar a uno que se podía ayudar cuesta mucho. El accuracy (0,76) es menor que el 83 % de un modelo ingenuo, pero ese modelo tendría recall igual a cero. El ROC-AUC de 0,74 indica una capacidad de ordenamiento moderada.



Figura 9. Variables con mayor peso en el modelo.

Variables utilizadas: las 21 variables del formulario (14 numéricas y 7 categóricas). Las de mayor peso son el promedio académico y las faltas al mes, seguidas por apoyo familiar, situación de pago, sede, horas de trabajo y cursos desaprobados.

Análisis de errores: los 7 falsos negativos tienen mejor rendimiento y asistencia que los verdaderos positivos (promedio 13,1 frente a 11,5; asistencia 86,4 % frente a 76,0 %). Probablemente abandonan por motivos que el dataset no captura, como razones personales o de salud.

11. Aplicativo web

Arquitectura

Aplicación Flask de servidor (Python) con plantillas HTML (Jinja2) y CSS propio; no requiere JavaScript. El modelo se carga una sola vez al iniciar. Se despliega en **Vercel** desde un repositorio de **GitHub**.

Estructura de carpetas

```
04_APLICATIVO/
├── app.py                  # rutas, validación, predicción y explicación
├── requirements.txt        # versiones exactas (la misma de scikit-learn del entrenamiento)
├── vercel.json
├── modelo/
│   ├── modelo_desercion.pkl
│   └── metricas.json       # métricas, fecha y variables que muestra la página "Modelo"
├── templates/              # base, index, predecir, resultado, modelo, 404
└── public/                 # css/estilos.css, icon.svg, manifest.webmanifest
```

Cómo Flask carga el .pkl

```
MODELO = joblib.load(BASE_DIR / "modelo" / "modelo_desercion.pkl")   # una sola vez
COLUMNAS = list(MODELO.feature_names_in_)

fila = pd.DataFrame([datos], columns=COLUMNAS)
probabilidad = float(MODELO.predict_proba(fila)[0, 1])
nivel = clasificar_riesgo(probabilidad)   # Bajo < 25 %, Medio 25-50 %, Alto >= 50 %
```

Flujo de predicción

- El usuario completa el formulario (21 datos; 7 son opcionales y, si se dejan vacíos, el pipeline los imputa con mediana o moda).
- El servidor valida tipos y rangos y devuelve mensajes de error claros si algo no es válido.
- Se construye un DataFrame de una fila y el pipeline aplica el mismo preprocesamiento del entrenamiento.
- El modelo devuelve la probabilidad; se convierte en nivel de riesgo, interpretación y recomendación.
- Se calcula el aporte de cada variable (coeficiente por valor estandarizado) para mostrar los factores que más pesan y sugerir acciones de seguimiento.

Niveles de riesgo (decisión de diseño)

Nivel	Probabilidad	Acción
Bajo	menor a 25 %	Seguimiento regular
Medio	de 25 % a menos de 50 %	Conversación preventiva con el tutor
Alto	50 % o más	Revisión prioritaria y plan de apoyo

Los rangos coinciden con el umbral de 0,5 con que el modelo clasifica. En la evaluación, la tasa real de abandono crece con cada nivel: 5,4 % en Bajo, 10,4 % en Medio y 37,1 % en Alto. Como el entrenamiento usa pesos de clase balanceados, el valor es un **índice de riesgo** y no una probabilidad real calibrada.

Pantallas principales

La aplicación usa una paleta blanco-gris con azul eléctrico y animaciones solo con CSS (anillo de riesgo que se llena, contadores, barras de factores, fondo en movimiento y barra inferior tipo app en celular). Respeta la preferencia de movimiento reducido del sistema.



Figura 10. Inicio, formulario y resultado en celular.



Figura 11. Página de información del modelo en escritorio.

Publicación en GitHub y Vercel

- Se sube la carpeta completa del proyecto a un repositorio de GitHub.
- En Vercel se importa el repositorio y se define **Root Directory = 04_APLICATIVO**; Vercel detecta Flask (app.py con la variable app) e instala requirements.txt.
- Los archivos estáticos están en **public/** porque Vercel los sirve desde esa carpeta; Flask está configurado para usarla también en local.
- Cada nuevo commit en GitHub vuelve a desplegar automáticamente.

12. Resultados

El modelo cumple su propósito de **apoyo a la priorización**: detecta cerca de dos de cada tres casos de abandono (recall 0,65) y los agrupa en niveles de riesgo coherentes, donde el nivel Alto abandona unas siete veces más que el nivel Bajo. Su capacidad de discriminación es moderada (ROC-AUC 0,74), consistente con las correlaciones individuales débiles observadas. Genera 22 falsas alertas sobre 100 estudiantes que continúan y deja pasar 7 de 20 abandonos.

Es útil como filtro para decidir a quién revisar primero, pero no como criterio único. Además de la probabilidad, la aplicación entrega los factores que más pesan en cada caso y acciones de seguimiento, lo que le da valor práctico al tutor.

13. Limitaciones

- **Datos sintéticos:** el comportamiento no proviene de estudiantes reales; las métricas son demostrativas y no se pueden extrapolar.
- **Muestra pequeña:** solo 20 casos de abandono en la prueba; una sola persona más o menos cambia el recall en 5 puntos.
- **Variables faltantes:** no se capturan motivos personales, de salud o de vocación; los falsos negativos probablemente abandonan por ellos.
- **Probabilidades no calibradas:** el balanceo de clases infla el valor, que debe leerse como índice de riesgo.

- **Equidad no evaluada:** no se analizó si el modelo se comporta igual entre sedes, programas o edades.
- **Modelo lineal:** no captura interacciones complejas entre variables.

14. Conclusiones

- Se cumplió el flujo completo: exploración, preprocesamiento, matemática, estadística, visualización, modelo, aplicativo web y documentación.
- El dataset está desbalanceado (16,7 % de abandono), por lo que accuracy no basta; se evaluó con precision, recall, F1, matriz de confusión y ROC-AUC.
- El abandono se asocia a factores académicos (promedio, faltas, asistencia) y de contexto (apoyo familiar, cuotas pendientes, conectividad, sede).
- La Regresión Logística superó al Random Forest en recall (0,54 frente a 0,08 en validación cruzada) y es interpretable, ventaja para usuarios no técnicos.
- El pipeline guardado en .pkl se integró en Flask y permite predecir sin reentrenar, con interfaz responsive usable desde el celular.
- El sistema es una herramienta de apoyo y no reemplaza el criterio del tutor.

15. Recomendaciones

- Validar el modelo con datos reales y anonimizados de la institución antes de cualquier uso operativo.
- Recalibrar las probabilidades (por ejemplo con calibración de Platt o isotónica) para mostrar probabilidades reales.
- Incorporar variables nuevas: motivos declarados, notas por curso, evolución mensual de asistencia y participación en actividades.
- Evaluar la equidad del modelo entre sedes, programas y grupos de edad.
- Probar otros algoritmos (gradient boosting) con más datos y ajustar el umbral según la capacidad de tutoría disponible.
- Agregar autenticación de tutores, historial de evaluaciones y reentrenamiento periódico.
- Definir protocolos de protección de datos personales y un seguimiento de si las intervenciones realmente reducen el abandono.

16. Anexos

Anexo A. Pipeline de preprocesamiento y modelo

```
transf_num = Pipeline([("imputar", SimpleImputer(strategy="median")),
                       ("escalar", StandardScaler())])
transf_cat = Pipeline([("imputar", SimpleImputer(strategy="most_frequent")),
                       ("codificar", OneHotEncoder(handle_unknown="ignore"))])
preprocesador = ColumnTransformer([("num", transf_num, cols_num),
                                   ("cat", transf_cat, cols_cat)])

modelo_final = Pipeline([("prep", preprocesador),
                         ("modelo", LogisticRegression(C=0.1, max_iter=2000,
                                                       class_weight="balanced"))])
modelo_final.fit(X_train, y_train)
joblib.dump(modelo_final, "../03_MODELO/modelo_desercion.pkl")
```

Anexo B. Funciones de varianza y desviación manual

```
def varianza_manual(datos):
    datos = np.array(datos, dtype=float)
    media = np.sum(datos) / len(datos)
    return np.sum((datos - media) ** 2) / (len(datos) - 1)

def desviacion_manual(datos):
    return np.sqrt(varianza_manual(datos))
```

Anexo C. Respuestas a las preguntas guía

1. ¿Por qué este dataset es adecuado para estudiar el riesgo de deserción?

Reúne en un solo lugar variables académicas (promedio, asistencia, cursos desaprobados), de hábitos (estudio, plataforma, tutorías) y de contexto (trabajo, traslado, pagos, conectividad, apoyo familiar), junto con la variable real de resultado. Eso permite estudiar cómo se combinan los factores. Al ser sintético, es seguro para practicar, aunque no representa estudiantes reales.

2. ¿Por qué es necesario tratar los valores nulos antes de entrenar?

Porque la mayoría de los algoritmos, incluida la regresión logística, no aceptan valores vacíos y fallan. Además, eliminar filas desperdiciaría datos de un dataset pequeño. Por eso se imputaron con mediana (numéricas) y moda (categóricas) dentro del pipeline.

3. ¿Qué variables parecen tener mayor relación con el abandono?

El promedio académico, las faltas al mes y la asistencia entre las numéricas; y el apoyo familiar bajo, las cuotas pendientes, la conectividad limitada y algunas sedes entre las categóricas. En el modelo pesan más el promedio y las faltas.

4. ¿Qué información aportan la varianza y la desviación estándar?

Miden cuánto se dispersan los datos respecto de la media. La desviación está en las mismas unidades de la variable, por eso es más fácil de interpretar: por ejemplo, el promedio varía unos 2,4 puntos y las horas de estudio unas 4 horas alrededor de su media.

5. ¿Qué valores atípicos encontraron y cómo decidieron tratarlos?

Promedios muy bajos (6,3 a 7,1), 2 estudiantes con más de 21 horas de estudio y 11 trayectos de 94 a 114 minutos. No se eliminaron porque son situaciones reales y justamente las de mayor interés; el escalado y la regularización reducen su influencia.

6. ¿Por qué la normalización puede ser importante para algunos algoritmos?

Porque variables con escalas muy distintas (asistencia de 0 a 100 frente a faltas de 0 a 9) harían que las de mayor magnitud dominen el ajuste en modelos basados en distancias o pesos, como la regresión logística regularizada. Estandarizar pone todas en la misma escala y hace comparables los coeficientes.

7. ¿Por qué no es suficiente evaluar este problema únicamente con accuracy?

Porque solo 16,7 % de los estudiantes abandona: un modelo que siempre diga 'continúa' tendría 83 % de accuracy y detectaría a nadie. Hacen falta recall, precision, F1 y la matriz de confusión para ver cómo se comporta con la clase que interesa.

8. ¿Qué significa el recall en un problema de detección de riesgo?

Es la proporción de estudiantes que realmente abandonan y que el modelo logra detectar. Un recall de 0,65 significa que se detectaron 13 de 20. Es la métrica prioritaria porque un falso negativo es un estudiante en riesgo que nadie revisará.

9. ¿Qué limitaciones tiene un modelo construido con datos sintéticos?

No refleja la complejidad ni los motivos reales del abandono, puede contener patrones simples creados por quien generó los datos y no permite medir su desempeño real. Sus métricas no son extrapolables a estudiantes reales.

10. ¿Qué mejoras realizarían antes de utilizar una solución similar en un entorno real?

Entrenar con datos reales y anonimizados, recalibrar probabilidades, agregar variables de motivos y evolución en el tiempo, evaluar la equidad entre grupos, proteger los datos personales, incluir autenticación y medir si las intervenciones reducen el abandono.

Anexo D. Evidencias de ejecución

El cuaderno **01_JUPYTER/analisis_desercion.ipynb** se entrega ya ejecutado, con todas sus salidas, gráficos e interpretaciones. Los gráficos están en 05_DOCUMENTACION/graficos y las capturas de la aplicación en 05_DOCUMENTACION/capturas.